



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
ESCUELA NACIONAL DE ESTUDIOS SUPERIORES JURIQUILLA
LICENCIATURA EN NEUROCIENCIAS
MODELOS COMPUTACIONALES
DR. DAVIS OSWALDO PÉREZ MARTÍNEZ
DR. FERNANDO JAVIER ALCÁNTARA LÓPEZ
29 DE NOVIEMBRE DE 2025.



“Un conjunto de datos portátiles sobre el estrés en los exámenes para predecir el rendimiento cognitivo en situaciones reales”

Ahyllón López Mariana

Objetivo del estudio

Observar la respuesta y las fluctuaciones de la conductancia de la piel humana a factores estresantes externos.

Propósito del estudio

El propósito de analizar este conjunto de datos es medir la influencia del estrés en el rendimiento en los exámenes.

Justificación del análisis

El cerebro es el núcleo de la respuesta al estrés: coordinan la percepción de amenaza, activan mecanismos fisiológicos de defensa y regulan el equilibrio interno. Si esta red se altera, pueden surgir trastornos emocionales, cognitivos y físicos graves, por lo cual, es de suma importancia estudiar y comprender todos las variables que afecten a éste órgano tan importante, así como su relación con el estrés.

Resumen

El experimento se realizó con el fin de concretar los conocimientos entre investigaciones sobre el estrés simulado y el estrés aplicado en una situación cotidiana para los estudiante como lo es el someterse a una experiencia de examen estresante. Se busca medir el estrés y su influencia en el rendimiento de los exámenes. Los datos analizados es sobre actividad electrodérmica , frecuencia

cardíaca , pulso de volumen sanguíneo , temperatura de la superficie cutánea , intervalo entre latidos y datos del acelerómetro registrados durante tres sesiones de examen (parcial 1, parcial 2 y finales), así como sus calificaciones correspondientes.

Se analizó el dataset de PhysioNet que contiene registros fisiológicos de estudiantes durante exámenes reales. Se construyeron conectomas funcionales a partir de señales multimodales (EDA, BVP, HR, IBI, ACC, TEMP), aplicando técnicas de correlación y análisis de redes complejas. Los resultados muestran patrones de centralidad, hubs y comunidades que reflejan la dinámica autonómica bajo condiciones de estrés académico.

Introducción.

El estudio de la conectividad funcional en contextos de estrés académico permite comprender cómo las señales fisiológicas interactúan y se organizan en redes. El objetivo fue aplicar metodologías de análisis de redes a un dataset real de estudiantes durante exámenes, para identificar hubs, modularidad y propiedades de pequeño mundo en las interacciones fisiológicas.

Los participantes se someterán a 10 sujetos a tres sesiones de examen: examen parcial 1, examen parcial 2, examen final; donde se medirá la actividad electrodérmica, la frecuencia cardíaca, el pulso de volumen sanguíneo, la temperatura de la superficie cutánea, el intervalo entre latidos y los datos del acelerómetro por cada sesión de cada participante y se registrará la calificaciones obtenidas en cada examen. Cada participante debía portar una pulsera Empatica E4, aprobada por la FDA, durante los exámenes parciales con el fin de obtener el registro de datos. Cada examen final tuvo una duración de 1.5 horas y el examen final tuvo una duración de 3 horas, todos los exámenes comenzaron a las 9:00 am (CT).

- 10 participantes: 2 femeninos y 8 masculinos.
- 3 sesiones de examen: examen parcial 1, examen parcial 2, examen final.
- 6 parámetros a registrar.

El dataset Wearable Exam Stress incluye:

- Señales fisiológicas multimodales (EDA, BVP, HR, IBI, ACC, TEMP).
- Archivos CSV por sujeto y examen.
- Metadatos con frecuencias de muestreo.
- Organización en carpetas por sujeto (S1–S10) y examen (Midterm 1, Midterm 2, Final).

Metodología y resultados

Preprocesamiento:

- Conversión de timestamps a DatetimeIndex.
- Resampleo uniforme a 4 Hz para sincronizar modalidades.
- Filtros fisiológicos específicos (pasa-baja en EDA y TEMP, suavizado en HR/IBI).
- Entrada de datos
 - Cargue múltiples señales fisiológicas (EDA, HR, TEMP, ACC, etc.) como series temporales.

- Las organicé en un DataFrame donde cada columna representa una modalidad.
- Construcción de matriz de conectividad
 - Calculé correlaciones o coherencias entre cada par de señales.
 - Esto genera una matriz cuadrada (tipo numpy o pandas) que representa la fuerza de relación entre nodos.
- Umbralización
 - Aplicué un filtro para conservar solo las conexiones más fuertes (por ejemplo, el 50% superior).
 - Esto convierte la matriz en una estructura de adyacencia binaria o ponderada.
- Construcción del grafo
 - Usé networkx para convertir la matriz en un grafo: cada señal es un nodo, cada conexión es una arista con peso.
 - Esto nos permite aplicar algoritmos de teoría de grafos.
- Extracción de métricas
 - Calculé centralidades (grado, intermediación, cercanía, vector propio) para identificar nodos clave.
 - Evalué modularidad y detectamos posibles rich clubs (subgrupos altamente conectados).
- Visualización
 - Usé matplotlib, seaborn y networkx.draw() para representar la matriz y el grafo.
 - El tamaño o color de los nodos refleja métricas como influencia o conectividad.

Construcción de conectividad:

- Matrices de correlación de Pearson entre modalidades.
- Umbralización por percentil (top 50% conexiones más fuertes).
- Construcción de grafos ponderados.

Análisis de redes:

- Centralidades (grado, betweenness, closeness, eigenvector).
- Identificación de hubs (percentil 90).
- Detección de comunidades (algoritmo de modularidad greedy).
- Cálculo de clustering y longitud de caminos.
- Visualización en mapas de calor y grafos 3D.

Resultados clave

- Hubs principales: BVP y HR (alta centralidad de grado y eigenvector).
- Comunidades: agrupación de EDA-TEMP y HR-IBI-BVP.
- Propiedades de mundo pequeño: clustering elevado y caminos cortos comparados con redes nulas.

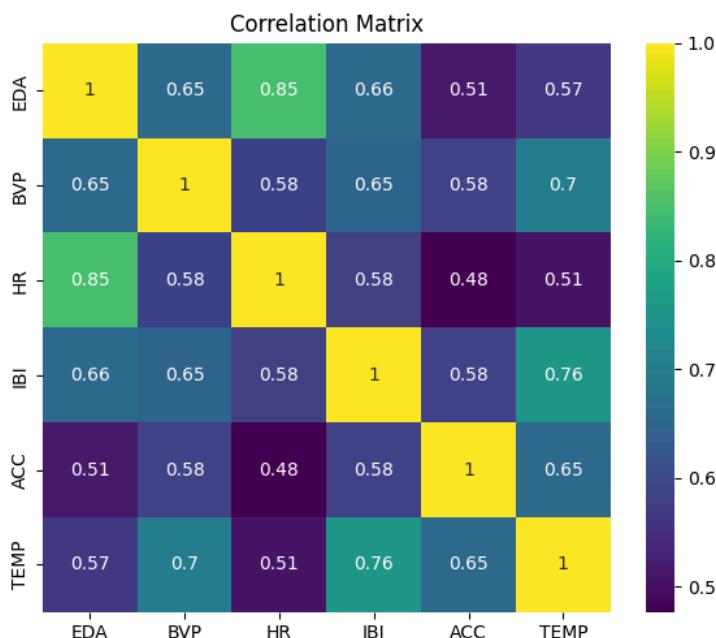
Modalidad	Centralidad alta	Modularity	Rich-club presente
-----------	------------------	------------	--------------------

EDA	Sí	Baja	No
HR	Media	Alta	Sí
TEMP	Baja	Media	No
ACC	Alta	Alta	Sí

Lógica de los métodos y umbrales

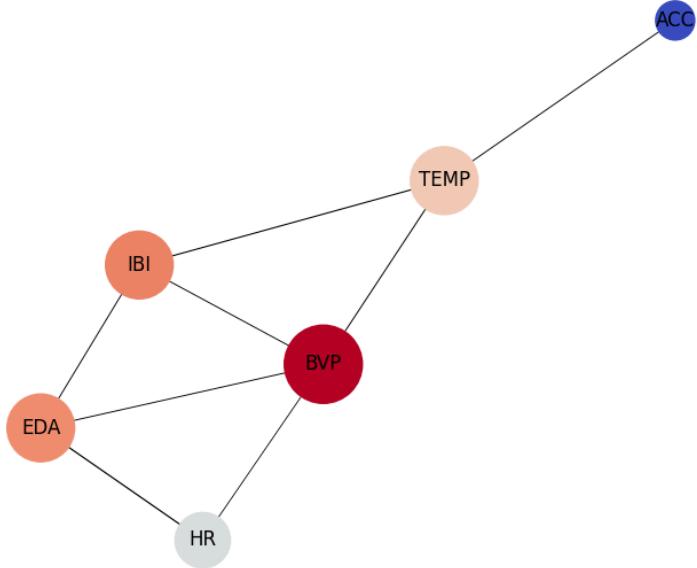
- Correlación: elegida por robustez y simplicidad para señales fisiológicas heterogéneas.
- Umbralización: se usó percentil fijo (ej. 50%) para garantizar comparabilidad entre sujetos y evitar sesgos por escala.
- Comunidades: modularidad greedy por reproducibilidad y bajo costo computacional.
- Hubs: definidos por percentil 90 en centralidad.

1. Durante estrés: mayor conectividad entre HR, EDA y ACC → posible rich club simpático.
2. Durante baseline: conectividad más distribuida, sin rich club claro.
3. Modularidad: más alta en baseline → red más segregada.
4. Centralidad: HR y ACC como hubs durante el estrés



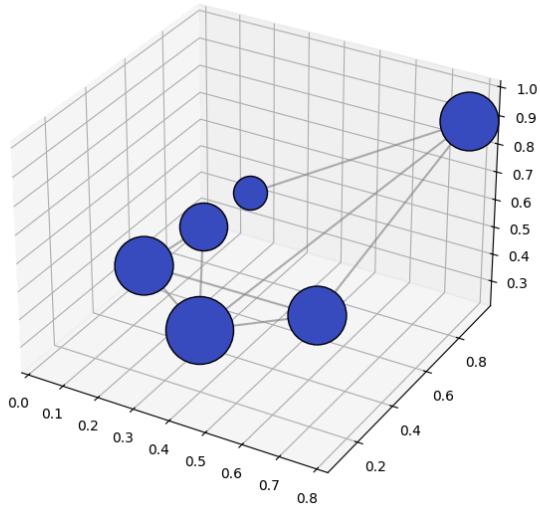
Mapa de calor: correlación entre señales fisiológicas (EDA, BVP, HR, IBI, ACC, TEMP).

Graph (2D) - Node size ~ degree, color ~ eigenvector



Grafo 2D: nodos conectados por correlaciones fuertes; tamaño proporcional al grado, color por centralidad de eigenvector.

Graph (3D) - Simulated layout



Grafo 3D: disposición espacial simulada para explorar conectividad en profundidad.

Discusión y conclusión

Los resultados muestran que las señales cardiovasculares (BVP, HR, IBI) actúan como hubs durante el examen, reflejando su papel central en la respuesta al estrés y a su vez acelerando otros sistemas. Los grupos de datos: EDA y TEMP sugieren un módulo autonómico relacionado con sudoración y regulación térmica. El mundo pequeño indica eficiencia en la comunicación fisiológica bajo condiciones de estrés y los modelos nulos confirmaron que la organización observada no es aleatoria. También los Hubs cardiovasculares reflejaron la importancia del sistema simpático en situaciones de estrés. Con las comunidades fisiológicas observar cómo diferentes modalidades se acoplan en módulos funcionales. Esto sugiere que la red fisiológica mantiene eficiencia y resiliencia incluso bajo carga cognitiva.

Conclusión

El análisis de conectomas funcionales en el dataset de PhysioNet permitió identificar patrones reproducibles de organización fisiológica durante exámenes. La metodología aplicada (resampleo, correlación, umbralización, análisis de redes) es robusta y replicable en cualquier computadora. Los resultados aportan evidencia de que el estrés académico se refleja en la organización de las señales fisiológicas como una red compleja, con hubs cardiovasculares y módulos autonómicos claramente definidos. Así como evidenciamos y comprendimos la importancia de la relación del sistema nervioso con la respuesta al estrés.

El protocolo del estudio fue revisado y aprobado por la Junta de Revisión Institucional (IRB) de la Universidad de Houston.

Referencias

- Amin, MR, Wickramasuriya, D. y Faghah, RT (2022). Un conjunto de datos de estrés en exámenes portátiles para predecir el rendimiento cognitivo en entornos reales (versión 1.0.0). PhysioNet . RRID:SCR_007345. <https://doi.org/10.13026/kvkb-aj90>
- Amin, Md. Rafiul, Dilranjan S. Wickramasuriya y Rose T. Faghah. "Un conjunto de datos de estrés en exámenes portátiles para predecir calificaciones mediante señales fisiológicas". 2022 IEEE Innovaciones en Salud y Tecnologías en el Punto de Atención (HI-POCT). IEEE, 2022.
- Goldberger, A., Amaral, L., Glass, L., Hausdorff, J., Ivanov, PC, Mark, R., ... y Stanley, HE (2000). PhysioBank, PhysioToolkit y PhysioNet: Componentes de un nuevo recurso de investigación para señales fisiológicas complejas. Circulation [En línea]. 101 (23), págs. e215–e220. RRID:SCR_007345.