

Comparación de la Reorganización de la Red Cerebral: repaso activo vs. repaso pasivo

Introducción

El repaso activo mejora la retención a largo plazo más que los métodos pasivos (Bertilsson et al., 2020), Además, la literatura reciente indica que durante las etapas iniciales del aprendizaje, los enfoques activos tienden a superar a los pasivos, en gran parte debido a una mayor motivación y actitud positiva del alumnado (Kooloos et al., 2020). Para comparar cómo el estudio activo y pasivo afectan la actividad cerebral, se utilizará un dataset público con registros EEG tomados antes y después de cada método. Buscando responder a la pregunta: ¿Dónde se concentran las diferencias en la actividad cerebral entre el estudio activo vs. estudio pasivo?

Descripción del datos y experimento

El experimento contó con 14 estudiantes divididos en 2 grupos, estudio activo (utilizaron una plataforma de aprendizaje con retroalimentación (10 preguntas con feedback inmediato) y estudio pasivo (los participantes revisaron sus propias notas). Todo recibieron una clase inicial. Se realizó un registro EEG antes de la actividad (pre-EEG). Después, cada participante completo la tarea asignada según su grupo, y al finalizar se registró un segundo EEG (post-EEG). Fueron 4 bloques: 2 con ojos abiertos y 2 con ojos cerrados. Se utilizó un sistema de 32 canales con electrodos activos Ag/AgCl, colocados según el sistema internacional 10–20, con muestreo a 500 Hz, filtrado entre 0.5 y 50 Hz.

Este dataset forma parte del repositorio abierto OpenNeuro (código: ds006801). El conjunto de datos sigue el estándar BIDS (Brain Imaging Data Structure). Contenía archivos. eeg (los datos brutos), .vhdr (incluye información esencial sobre los canales y la frecuencia de muestreo) y .vmrk (registra los eventos ocurridos durante la sesión). Todos estos archivos son necesarios para leer correctamente un registro EEG en formato BrainVision.

Metodología y resultados

- 1) Cargar librerías

Se cargaron las librerías necesarias que permiten desde la lectura de archivos hasta el análisis y visualización de los grafos y graficas.

De descargo la biblioteca “mne-phyton”, un código abierto diseñado para la exploración, visualización y análisis de datos neurofisiológicos. Se empleo para cargar los archivos BrainVision (.eeg, .vhdr, .vmrk).

```
import numpy as np
import mne
import warnings
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import seaborn as sns
from mi_modulo import *
import networkx as nx
from networkx.algorithms import community
```

También se cargó “mi_modulo”, un módulo personalizado con funciones propias diseñado para simplificar el análisis y reducir el código.

2) Cargar datos

Se cargaron los archivos EEG en formato BrainVision utilizando la función cargar_brainvision, que permite leer los registros pre y post intervención de cada sujeto. Obteniendo los datos brutos.

3) Detección de canales malos por varianza

Se utilizo la función “detectar_canales_malos_por_varianza” para identificar canales EEG que presente un comportamiento atípico, es decir canales con varianza o muy alta o baja en comparación con el resto.

```
def detectar_canales_malos_por_varianza(raw, factor=3.0):

    ##Detecta canales malos usando varianza (outliers).
    ##factor: número de desviaciones estándar para marcar un outlier.

    data = raw.get_data()
    var = np.var(data, axis=1)

    mean = np.mean(var)
    std = np.std(var)

    umbral_alto = mean + factor * std
    umbral_bajo = mean - factor * std

    idx_malos = np.where((var > umbral_alto) | (var < umbral_bajo))[0]
    nombres_malos = [raw.ch_names[i] for i in idx_malos]

    return nombres_malos, var
```

A partir de la media y la desviación estándar de la varianza se calcularon los umbrales superior e inferior, cualquier canal cuya varianza exceda estos umbrales establecidos se considerarán malos.

4) Interpolación de canales malos

Para evitar que el comportamiento atípico de los canales afecte la calidad del EEG, se interpolaron reconstruyendo su señal a partir de los canales vecinos. Los canales malos fueron muy pocos, indicando que el EEG es relativamente estable.

5) Separación de sesiones de ojos abiertos y cerrados

Para analizar de manera consistente la actividad en estado de reposo, sin influencia de la visión, separe los periodos de ojos cerrado de ojos abiertos con la función “obtener cerrados”. Esta función extrae los bloques correspondiente de cada registro y los concatena, generando matrices.


6) Matriz de conectividad por correlación

Se utiliza la correlación de Pearson para calcular la conectividad entre canales, mediante la función “matriz_corr”. Elegí la correlación porque permite evaluar la interacción funcional global entre regiones cerebrales de manera sencilla, facilitando la comparación entre condiciones y pre y post.

7) Decidir umbral y matriz binarizada


```
[12]: # Matriz binarizada grupo activo pre
plt.figure(figsize=(3,3))
sns.heatmap(resultado_activo_pre)
```

[12]: <Axes: >




```
# Matriz binarizada grupo activo post
plt.figure(figsize=(3,3))
sns.heatmap(resultado_activo_post)
```

[16]: <Axes: >




```
[132]: # Matriz binarizada pasivo Pre
plt.figure(figsize=(3,3))
sns.heatmap(resultado_pasivo_pre)
```

[132]: <Axes: >



```
[135]: # Matriz binarizada pasivo post
plt.figure(figsize=(3,3))
sns.heatmap(resultado_post)
```

[135]: <Axes: >



Se binarizaron las matrices de conectividad utilizando como umbral inicial la media del percentil 75% de los coeficientes de correlación. Este criterio permite resaltar únicamente las conexiones más fuertes y consistente, ya que el percentil 75% corresponde al valor por encima del cual se encuentra solo el 25% de los coeficientes más altos. Así, se destacan las interacciones más significativas, pero no tan extremo como para excluir demasiadas conexiones importantes.

8) Cálculo de métricas de red

Se aplicó la función “métricas_grafo” a todas las matrices de conectividad, esta función devuelve diversas métricas (coeficiente de clustering, longitud promedio de caminos, índice de mundo pequeño, comunidades detectadas, modularidad, intermediación, eficiencia global y local, y grado de los nodos).

9) Visualización de grafos

Se usó el montaje estándar 10-20 para obtener las posiciones espaciales de los electrodos. Las coordenadas se guardaron en un dataframe. Para cada tarea se generaron dos grafos: el grafo 3d (mostrando el hub principal (nodo con mayor intermediación/betweenness) y las comunidades detectadas) y el grafo 2D basado en la matriz binarizada de conectividad.

Discusión

Tabla con los cálculos de métrica grupo de estudio activo (Pre vs Post)

	Pre	Post
Coef. de clustering	0.6788	0.6545
Path length	nan	nan
Small-world sigma	nan	nan
Nº de comunidades	4	4
Modularidad	0.2203	0.2036
Global efficiency	0.5665	0.5840
Local efficiency	0.8037	0.7738
Top 3 betweenness	FC5 (0.0708) T8 (0.0679) CP6 (0.0639)	FC6 (0.0828) FC5 (0.0753) CP5 (0.0675)
Grado máximo	17 (Oz)	18 (CP5 / P3)

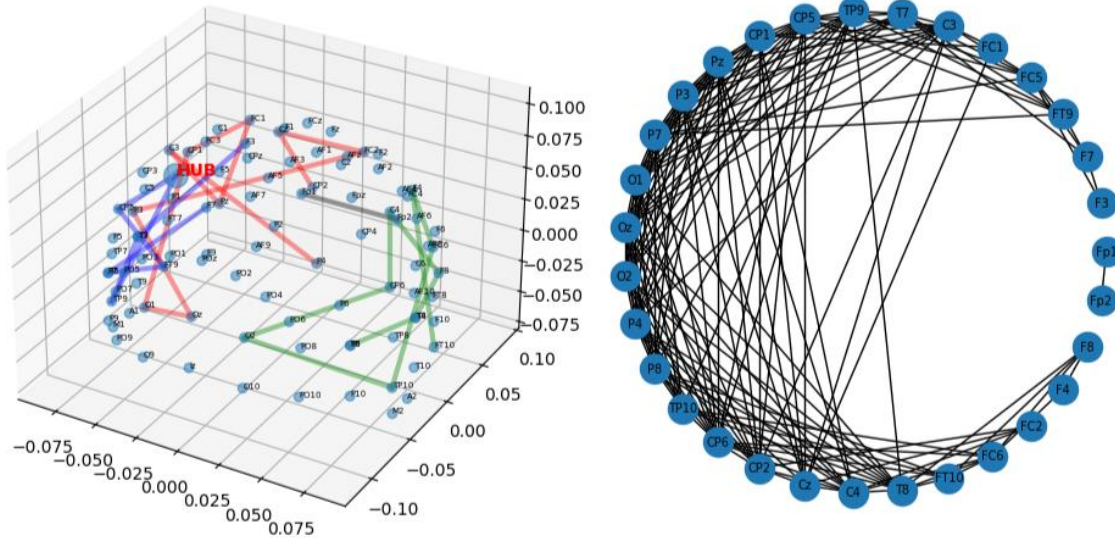
Tabla con los cálculos de métricas grupo de estudio pasivo (pre y post)

	Pre	Post
Coef. de clustering	0.5624	0.5913
Path length	nan	nan
Small-world sigma	nan	nan
Nº de comunidades	9	5
Modularidad	0.2179	0.2363
Global efficiency	0.3942	0.4965
Local efficiency	0.6620	0.7210
Top 3 betweenness	T7 (0.1529), P7 (0.1388), T8 (0.1098)	CP5 (0.1055), CP6 (0.0881), FC5 (0.0866)
Grado máximo	13 — P3, P8	15 — P4, CP6

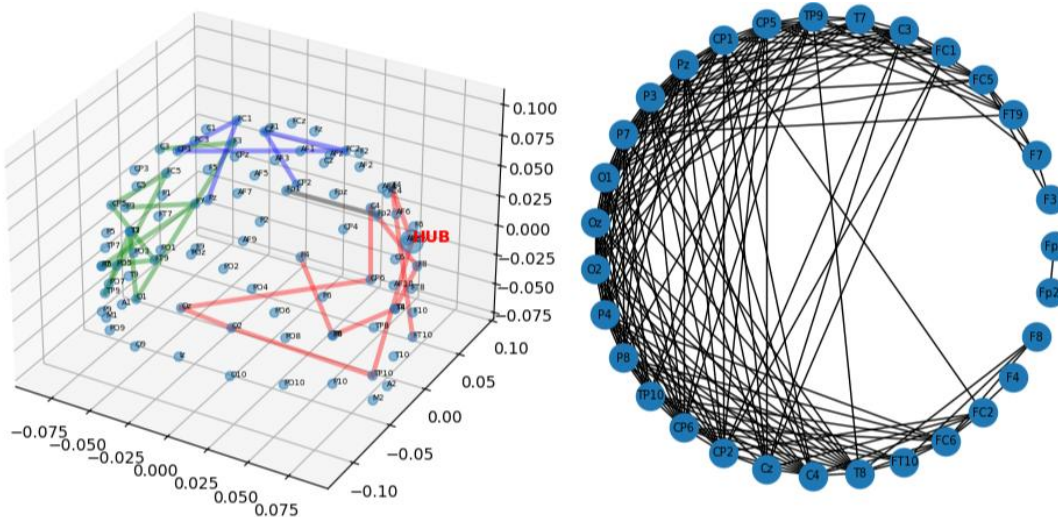
--	--	--

“Path length” y “small-world sigma” aparecen como nan porque la red binarizada presenta componentes desconectados (existen subgrafos aislados), por lo que la longitud de camino promedio no es definible sobre toda la red.

GRAFO GRUPO ACTIVO PRE-EEG



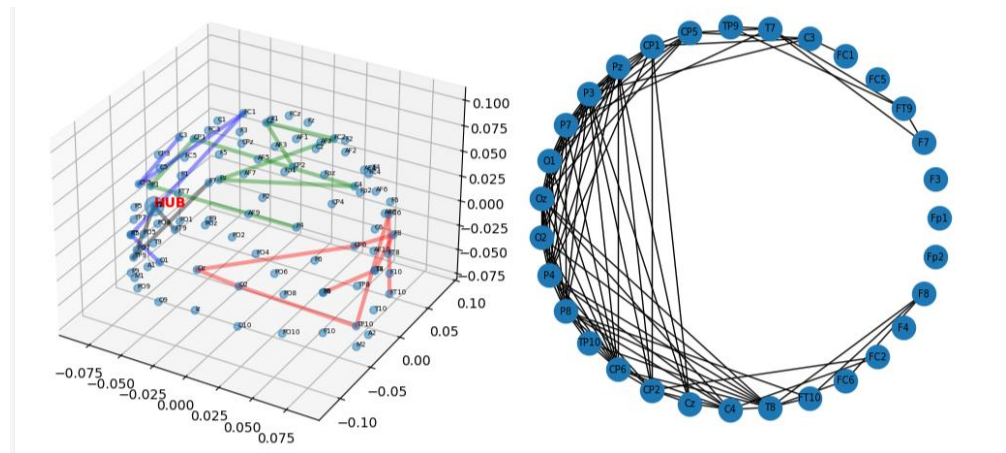
GRAFOS GRUPO ACTIVO POST-EEG



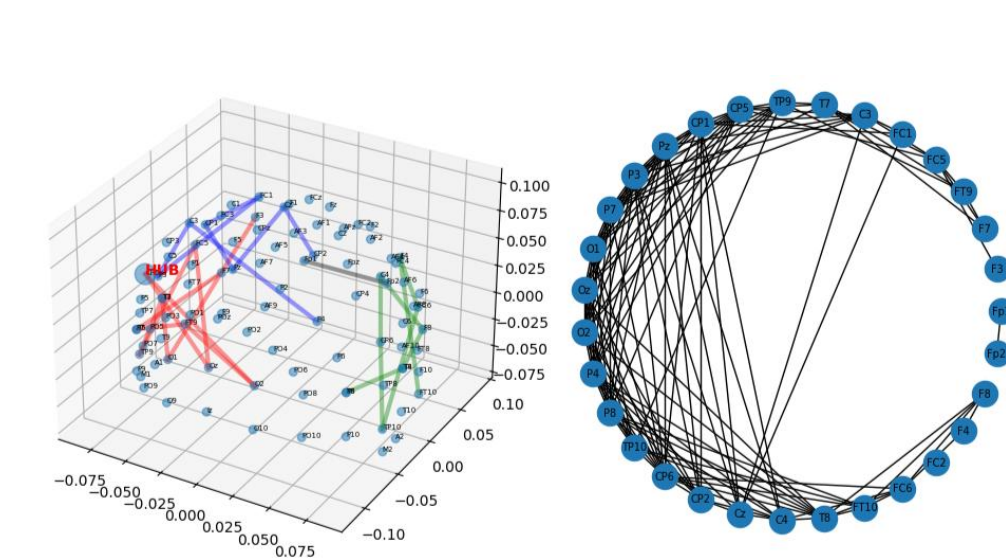
Tras la sesión con retroalimentación inmediata, se observa una disminución de la eficiencia local (0.80 a 0.77), del coeficiente de agrupamiento (0.67 a 0.65) y de la modularidad (0.22 a 0.20), indicando que los módulos están más interconectados. Después del aprendizaje con retroalimentación la red opera de forma más integrada, un patrón típico se consolidan procesos cognitivos.

En cuanto a los hubs, FC6 (frontocentral derecha) se convierte en el nodo con mayor intermediación en Post (0.0828), pasando a ser el principal punto de integración de la red. FC5 se mantiene como un nodo central antes y después de la intervención, reforzando el papel clave de la región frontocentral en los procesos ejecutivos. Los hubs derechos T8(temporal) y CP6(centro-parietal) presentes en Pre son sustituidos en Post por CP5, mostrando un desplazamiento de la integración desde áreas perceptivas hacia regiones frontales, más relacionadas con atención y memoria de trabajo durante el aprendizaje activo.

GRAFOS GRUPO PASIVO PRE-EEG



GRAFOS GRUPO PASIVO POST-EEG



La eficiencia local aumenta (0.66 a 0.72) lo que indica un procesamiento más rápido y organizado dentro de cada clúster. La modularidad y el agrupamiento también aumentan, mostrando una red más especializada, con módulos más definidos (de 9 a 5 comunidades).

Al igual que en el grupo activo, el hub post-EEG se desplaza hacia una región asociada con la consolidación de la memoria. En este caso, la red deja de apoyarse en T7, más ligado al procesamiento perceptivo-lingüístico, y pasa a organizarse alrededor de CP5. La presencia de T7 como hub pre puede relacionarse con la actividad de escritura previa a la sesión.

Conclusiones

Ambos grupos muestran reorganización de la red tras la intervención, pero con patrones distintos. En el Grupo Activo, la red se integra más, con hubs frontocentrales (FC6, FC5) dominando la intermediación, favoreciendo control ejecutivo y memoria de trabajo. En el Grupo Pasivo, la red se vuelve más modular y especializada, con el hub principal desplazándose de T7 a CP5, promoviendo consolidación y organización local de la información. En resumen, el repaso activo probablemente aumenta la integración, mientras que el repaso pasivo podría estar reforzando la consolidación.

Bibliografía

Bertilsson, F., Stenlund, T., Wiklund-Hörnqvist, C., & Jonsson, B. (2020). Retrieval Practice: Beneficial for All Students or Moderated by Individual Differences? *Psychology Learning & Teaching*, 20(4), 470–482.

<https://doi.org/10.1177/1475725720973494>

Kooloos, J. G. M., Bergman, E. M., Scheffers, M. A. G. P., Schepens-Franke, A. N., & Vorstenbosch, M. A. T. M. (2020). The Effect of Passive and Active Education Methods Applied in Repetition Activities on the Retention of Anatomical Knowledge. *Anatomical sciences education*, 13(4), 458–466.

<https://doi.org/10.1002/ase.1924>

Brain Products: Solutions for neurophysiological research. (s/f) *BrainVision Core Data Format (BVCDF)*. <https://www.brainproducts.com/support-resources/brainvision-core-data-format-1-0/>

Gallo Fraga, M. (2024, 11 septiembre). *Lóbulo parietal: integración sensorial y percepción espacial*. NeuroClass. <https://neuro-class.com/lobulo-parietal-integracion-sensorial-y-percepcion-espacial/>