

Comparación de la reorganización de la red cerebral: repaso activo vs repaso pasivo

Introducción

El repaso activo mejora la retención a largo plazo más que los métodos pasivos (Bertlisson et al.,2020). Además, la literatura reciente indica que durante las etapas iniciales del aprendizaje, los enfoques activos tienden a superar a los pasivos, en gran parte debido a una mayor motivación por parte del alumno (Kooloos et al.,2020). Para comparar cómo el repaso activo y pasivo afectan la actividad cerebral, se utilizará un dataset público con registros EEG tomado antes y después de cada método, buscando responder a la pregunta ¿Dónde se concentran las diferencias en la actividad cerebral entre el estudio activo vs estudio pasivo?

Descripción del los datos y experimento

El experimento contó con 14 estudiantes divididos en 2 grupos, estudio activo (utilizaron una plataforma de aprendizaje con retroalimentación inmediata) y estudio pasivo (los participantes revisaban sus propias notas). Todos recibieron una clase inicial. Se realizó un registro EEG antes de la actividad (pre-EEG). Después, cada participante completo su tarea correspondiente asignada, y al finalizarla se volvió a registrar un segundo EEG (post-EEG). Fueron 4 bloques en total con una duración de 9 minutos: 1 con ojos abiertos y 2 con ojos cerrados. Se utilizó 32 canales con electrodos activos, colocados según el sistema internacional 10-20, con muestreo a 500Hz y filtrado entre 0.5 a 50 Hz.

Este dataset forma parte del repositorio abierto OpenNeuro (código: ds006801). El conjunto de datos sigue el formato BIDS (Brain Imaging Data Structure). Para que el EEG sea leído correctamente se necesita de los archivos. eeg (los datos brutos) .vdhr (incluye información sobre los canales y frecuencia de muestreo) y .vmrk (registra los eventos ocurridos durante la sesión).

Metodología y resultados

1) Cargar librerías

Se cargaron las librerías necesarias que permiten desde la lectura de los archivos hasta el análisis y visualización de graficas y grafos.

De descargo la biblioteca “mne-phyton”, un código abierto diseñado para la explotación, visualización y análisis de datos neurofisiológicos. Se empleo para cargar los archivos BrainVision (.egg, .vdhr, vmrk).

```
import numpy as np
import mne
import warnings
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import seaborn as sns
from mi_modulo import *
import networkx as nx
from networkx.algorithms import community
```

Tambien cargue “mi_modulo”, donde tenía la amyoría de las funcionciones diseñadas para poder simplificar el análisis y reducir el código.

2) Cargar datos

Se cargaron los archivos EEG en formato BrainVision utilizando la función cargar_brainvision, esto permitió leer los registros pre y post intervención de cada sujeto. Obteniendo los datos brutos.

3) Detección de canales malos por varianza

Con la función “detectar_canales_malos_por_varianza” se identifico canales de EEG que mostraban un comportamiento atípico, es decir canales con varianza o muy alta o baja en comparación con el resto.

```
def detectar_canales_malos_por_varianza(raw, factor=3.0):

    ##Detecta canales malos usando varianza (outliers).
    ##factor: número de desviaciones estándar para marcar un outlier.

    data = raw.get_data()
    var = np.var(data, axis=1)

    mean = np.mean(var)
    std = np.std(var)

    umbral_alto = mean + factor * std
    umbral_bajo = mean - factor * std

    idx_malos = np.where((var > umbral_alto) | (var < umbral_bajo))[0]
    nombres_malos = [raw.ch_names[i] for i in idx_malos]

    return nombres_malos, var
```

A partir de la media y desviación estándar de la varianza se calcularon los umbrales superior e inferior. Cualquier canal cuya varianza exceda estos umbrales establecidos se consideraban malos.

4) Interpolación de canales malos

Para evitar que el comportamiento atípico de los canales afecte la calidad del EEG, se interpolaron reconstruyendo su señal a partir de los canales vecinos. Los canales malos fueron muy pocos, indicando que el EEG se encontraba relativamente estable.

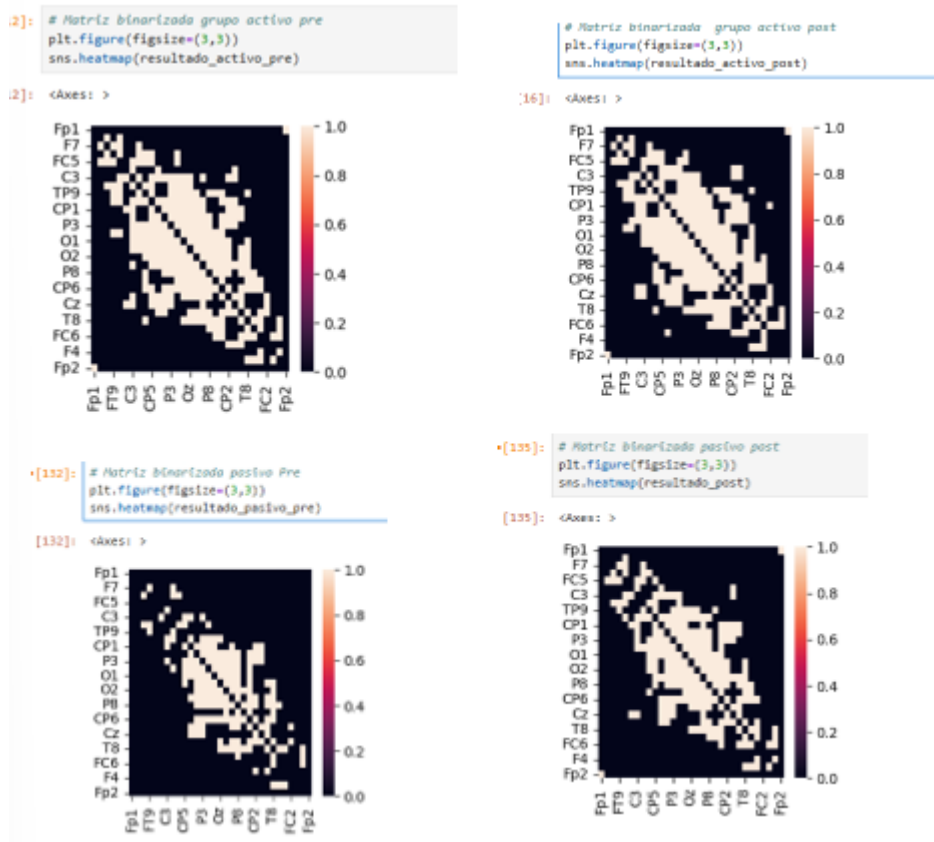
5) Separación de sesiones de ojos abiertos y cerrados

En este caso, solo tome en cuenta la sesión con los ojos abiertos, para que la señal no tuviera influencia de los movimientos oculares y la visión, por lo que separe las sesión es ojos cerrados de ojos abiertos con la función “obtener cerrados”. Los concatene y se generaron matrices de la sesión pre y post.

6) Matriz de conectividad por correlación

Utilice la correlación de Pearson para calcular la conectividad entre canales, mediante la función “matriz_corr”. Elegí este método porque permite evaluar la interacción funcional global entre regiones de manera sencilla, facilitando así la comparación entre condiciones y antes y después de la sesión.

7) Decidir umbral y matriz binarizada



Se binarizaron las matrices de conectividad utilizando como umbral inicial la media del percentil 75% de los coeficientes de correlación. Esto permitió resaltar únicamente las conexiones más fuertes y consistentes, ya que el percentil 75% corresponde al valor por encima del cual se encuentra solo el 25% de los coeficientes

más altos. Así, podemos detectar las interacciones más significativas, pero sin que se vaya al extremo como para excluir conexiones relevantes.

8) Cálculo de métricas de la red

Se aplicó la función “métricas_grafo” a todas las matrices de conectividad, esta función devuelve diversas métricas (tabla de las métricas encontradas en sección de discusión).

9) Visualización de grafos

Se usó el montaje estándar 10-20 para obtener las posiciones espaciales de los electrodos. Las coordenadas se guardaron en un dataframe. Para cada tarea se generaron 2 grafos:

- a. Grafo 3D: mostrando el hub principal (nodo con mayor intermediación/betweenness) y las comunidades detectadas
- b. Grafo 2D: basado en la matriz binarizada.

Discusión

Tabla con los cálculos de métrica grupo de estudio activo (Pre vs Post)

	Pre	Post
Coef. de clustering	0.6788	0.6545
Path length	nan	nan
Small-world sigma	nan	nan
Nº de comunidades	4	4
Modularidad	0.2203	0.2036
Global efficiency	0.5665	0.5840
Local efficiency	0.8037	0.7738
Top 3 betweenness	FC5 (0.0708) T8 (0.0679) CP6 (0.0639)	FC6 (0.0828) FC5 (0.0753) CP5 (0.0675)
Grado máximo	17 (Oz)	18 (CP5 / P3)

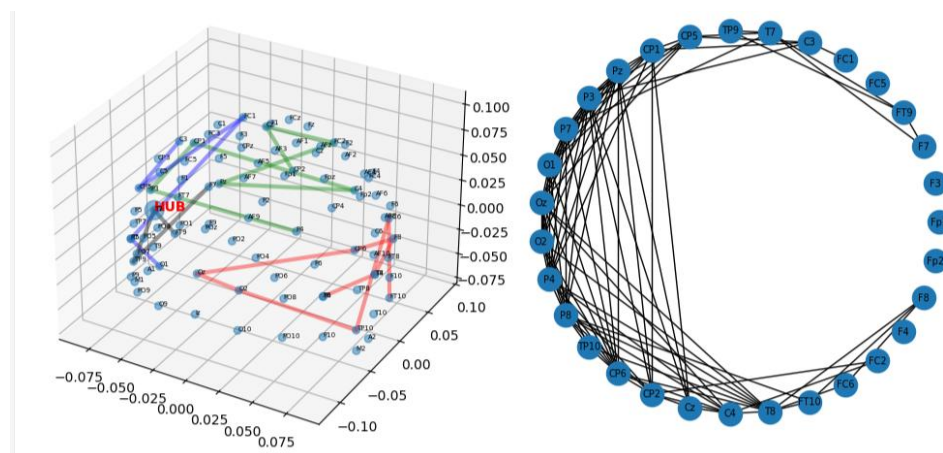
Tabla con los cálculos de métricas grupo de estudio pasivo (pre y post)

	Pre	Post
Coef. de clustering	0.5624	0.5913
Path length	nan	nan
Small-world sigma	nan	nan
Nº de comunidades	9	5
Modularidad	0.2179	0.2363

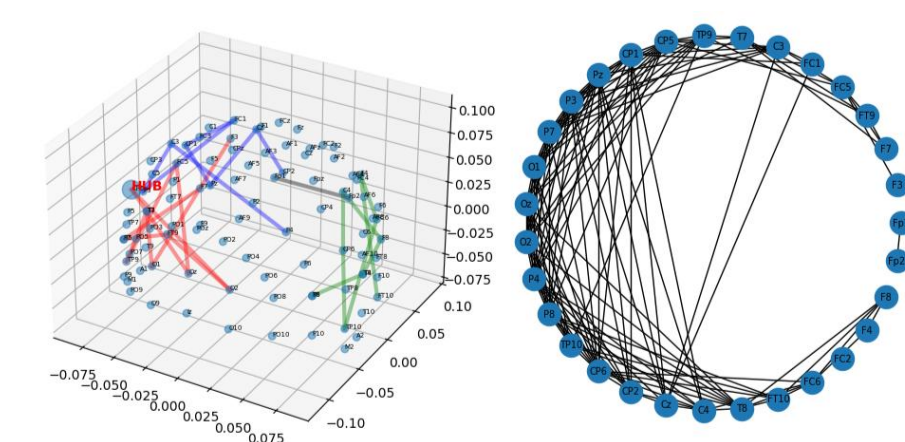
Tras la sesión con retroalimentación inmediata, se observa una disminución de la eficiente local (0.80 a 0.77), el coeficiente de agrupamiento (0.67 a 0.65) y de la modularidad (0.22 a 0.20), indicando que los módulos están más interconectados. Después del aprendizaje con retroalimentación la red parece estar operando de manera más integrada, un patrón que sucede en la consolidación de los procesos cognitivos.

En cuanto a los hubs, FC6 (frontocentral derecha) se convierte en el nodo con mayor intermediación en la sesión Post-retroalimentación, pasando a ser el principal punto de integración de la red. FC5 se mantiene como un nodo central antes y después de intervención, reforzando el papel clave del área frontocentral en los procesos ejecutivos. Los hubs T8 (temporal) y CP6 (centroparietal) presentes en Pre son sustituidos en post por CP5, mostrando un desplazamiento de áreas perceptivas hacia regiones frontales que se ven más relacionadas con la atención y memoria de trabajo.

GRAFOS GRUPO PASIVO PRE-EEG



GRAFOS GRUPO PASIVO POST-EEG



La eficiencia local aumenta (0.66 a 0.72) lo que indica un procesamiento más rápido y organizado dentro de cada clúster. La modularidad y el agrupamiento también aumentan, mostrando una red con módulos más definidos (de 9 a 5 comunidades).

Al igual que el grupo activo, el hub post-EEG se desplaza hacia regiones asociadas con las funciones ejecutivas. En este caso, la red deja de apoyarse en T7, más ligado al procesamiento perceptivo lingüístico, y pasa a organizarse alrededor de CP5. La presencia de T7 como hub pre puede relacionarse con la actividad de escritura previa a la sesión.

Conclusiones

Ambos grupos muestran reorganización de la red tras la intervención, pero con patrones un poco diferentes cada uno. En el grupo activo, la red se integra más, con hubs frontocentrales, favoreciendo el control ejecutivo. En el grupo pasivo, la red se vuelve más modular y especializada, con el hub principal desplazándose de T7 a Cp5, promoviendo la organización y consolidación local de la información. En resumen, el repaso activo probablemente aumenta la integración, mientras que el repaso pasivo podría estar reforzando la consolidación.

Bibliografía

Bertilsson, F., Stenlund, T., Wiklund-Hörnqvist, C., & Jonsson, B. (2020). Retrieval Practice: Beneficial for All Students or Moderated by Individual Differences? *Psychology Learning & Teaching*, 20(4), 470–482.

<https://doi.org/10.1177/1475725720973494>

Kooloos, J. G. M., Bergman, E. M., Scheffers, M. A. G. P., Schepens-Franke, A. N., & Vorstenbosch, M. A. T. M. (2020). The Effect of Passive and Active Education Methods Applied in Repetition Activities on the Retention of Anatomical Knowledge. *Anatomical sciences education*, 13(4), 458–466.

<https://doi.org/10.1002/ase.1924>

Brain Products: Solutions for neurophysiological research. (s/f) *BrainVision Core Data Format (BVCDF)*. <https://www.brainproducts.com/support-resources/brainvision-core-data-format-1-0/>

Google. (2025). *Gemini* (Modelo de lenguaje grande).

Gallo Fraga, M. (2024, 11 septiembre). *Lóbulo parietal: integración sensorial y percepción espacial*. NeuroClass. <https://neuro-class.com/lobulo-parietal-integracion-sensorial-y-percepcion-espacial/>